

Experimentos de análise espacial no GeoDa

Criminalidade nos 645 municípios de São Paulo: mapas exploratórios, matriz de ponderação espacial, Moran global e LISA

Equipe: João Vitor Oliveira, Julio Cesar Salvino e Lucas Amorim · **Orientação:** Prof.^a Flávia da Fonseca Feitosa
· **Software:** GeoDa (matriz queen de ordem 1, 999 permutações) · **Julho de 2026**

1. Objetivo e dados

Este relatório documenta os experimentos conduzidos no GeoDa com os dados do nosso trabalho final, aplicando as técnicas da aula prática: análise exploratória por mapas temáticos e medidas de autocorrelação espacial (índice global de Moran e índice local, LISA). As variáveis de interesse são as taxas por 1.000 habitantes de três crimes registrados pela SSP-SP em 2025: roubo (art. 157), furto (art. 155) e lesão corporal (art. 129). O denominador é a população residente do Censo 2022 (IBGE, Tabela 4709).

O arquivo de entrada, `data/geoda_sp.gpkg`, foi gerado pelo pipeline em R do projeto e reúne, para cada um dos 645 municípios, o código IBGE (`cod_ibge`, chave de identificação), as contagens (`n_roubo`, `n_furto`, `n_lesao`), as taxas (`tx_roubo`, `tx_furto`, `tx_lesao`), a renda média do Censo 2022 e a população. Trabalhamos sempre com as taxas: a contagem bruta mede, na prática, o tamanho da população de cada município, enquanto a taxa permite comparar municípios de portes muito diferentes. A seção 2.2 ilustra essa escolha.

2. Passo 1: análise exploratória com mapas temáticos

Espacializamos cada taxa de três maneiras, trocando o tipo de mapa com o botão direito sobre a janela (Change Current Map Type): por quantis, por desvio padrão e pelo box map com articulação 1,5. Cada tipo responde a uma pergunta diferente.

2.1 Mapas por quantil

O mapa de quantis divide os 645 municípios em cinco classes com o mesmo número de observações (cerca de 129 em cada), do quintil mais claro ao mais escuro. Ele mostra o padrão espacial relativo: onde estão os 20% de municípios com as maiores taxas. Sua limitação é depender da forma da distribuição; como as taxas são assimétricas, uma mesma classe pode reunir valores bem diferentes.




Figura 1. Mapas por quantil das taxas de roubo (acima), furto (abaixo, à esquerda) e lesão corporal (abaixo, à direita). No roubo há um gradiente claro do oeste para o leste, com a macrometrópole e o litoral no quantil superior; a primeira classe concentra 258 municípios porque muitos têm taxa de roubo próxima de zero, sinal de que o roubo é raro fora das aglomerações urbanas. No furto, o litoral inteiro aparece no quantil superior, de Ubatuba a Cananéia. Na lesão corporal o padrão é salpicado, sem concentração regional evidente.

2.2 Mapas por desvio padrão

O mapa por desvio padrão classifica cada município pela distância em relação à média estadual, medida em desvios padrão. Ele destaca o quão extremo cada valor é. Em distribuições assimétricas como as nossas, a maior parte dos municípios cai nas classes centrais e uma cauda pequena ultrapassa dois ou três desvios acima da média.




Figura 2. Mapas por desvio padrão das taxas de roubo, furto e lesão corporal. No roubo, 31 municípios ficam acima de três desvios da média, todos na RMSP e na Baixada Santista. No furto, a cauda extrema é litorânea. Na lesão, os municípios extremos se dispersam pelo interior, sem formar região.

Para justificar o uso de taxas, comparamos o mapa por desvio padrão da contagem bruta de roubos com o da taxa correspondente. Na contagem, apenas a capital e vizinhos imediatos se destacam, porque o número absoluto de ocorrências acompanha o tamanho da população. Na taxa, emerge o padrão territorial que interessa à análise.




Figura 3. Contagem de roubos (esquerda) e taxa por 1.000 habitantes (direita), ambas por desvio padrão. A contagem mapeia população; a taxa revela o padrão territorial do crime.

2.3 Box map (articulação 1,5)

O box map é a versão espacial do boxplot: as classes seguem os quartis e as categorias extremas marcam os outliers, definidos como valores acima de $Q3 + 1,5 \text{ IQR}$ ou abaixo de $Q1 - 1,5 \text{ IQR}$. É o mapa mais indicado para responder quem são os municípios atípicos e se eles se concentram no espaço.




Figura 4. Box maps (articulação 1,5) das três taxas. O roubo tem 60 outliers superiores, quase todos contíguos na RMSP e na Baixada Santista, um prenúncio do cluster que o LISA confirmará. O furto tem 17 outliers superiores, concentrados no litoral e na capital. A lesão corporal tem 22 outliers superiores dispersos (entre eles municípios muito pequenos, como Balbinos) e é a única taxa com outliers inferiores.

3. Passo 2: matriz de ponderação espacial

A matriz de ponderação operacionaliza a noção de vizinhança exigida pelos índices de autocorrelação. Criamos a matriz no Weights Manager usando `cod_ibge` como variável de identificação e o critério de contiguidade queen de ordem 1: dois municípios são vizinhos quando compartilham qualquer trecho de fronteira, ainda que um único ponto, em analogia ao movimento da rainha no xadrez. O GeoDa normaliza as linhas da matriz (row standardization), de modo que o lag espacial de uma variável corresponde à média dos valores dos vizinhos.




Figura 5. Propriedades da matriz criada: 645 observações, mínimo de 0 e máximo de 22 vizinhos, média de 5,50 e mediana de 5, com 0,85% de pesos diferentes de zero. Os valores são idênticos aos obtidos no R com `spdep::poly2nb`, o que confirma que a matriz foi construída da mesma forma nos dois softwares.

O mínimo de zero vizinhos corresponde a Ilhabela, que é um arquipélago e não toca nenhum outro polígono. O GeoDa avisa sobre a observação isolada e a remove do cálculo dos índices; no pipeline em R o tratamento equivalente é o argumento `zero.policy = TRUE`.

4. Passo 3: índice global de Moran e diagrama de espalhamento

O índice de Moran mede a autocorrelação espacial global: o grau em que valores semelhantes se aglomeram no território. Valores positivos indicam que municípios com taxas altas tendem a ter vizinhos com taxas altas (e vice-versa); valores próximos de zero indicam padrão aleatório; valores negativos indicariam um padrão de tabuleiro de xadrez. No diagrama de espalhamento, o eixo horizontal traz a variável padronizada e o eixo vertical o seu lag espacial; a inclinação da reta de regressão é o próprio índice. Os quadrantes classificam cada município: Alto-Alto e Baixo-Baixo indicam concordância com a vizinhança, Alto-Baixo e Baixo-Alto indicam discordância.




Figura 6. Diagramas de espalhamento de Moran. No roubo ($I = 0,832$) a reta se aproxima de 45 graus e a nuvem se concentra nos quadrantes concordantes. No furto ($I = 0,426$) a inclinação é menor e a dispersão maior, com os municípios litorâneos puxando o quadrante Alto-Alto. Na lesão corporal ($I = 0,183$) a reta é quase horizontal; o ponto isolado à direita é Balbinos, taxa muito alta cercada de vizinhos na média, um outlier espacial clássico.

4.1 Significância por permutação

A significância foi avaliada por aleatorização com 999 permutações: o GeoDa redistribui os valores observados ao acaso entre os municípios e recalcula o índice a cada permutação, construindo a distribuição de referência sob a hipótese de aleatoriedade espacial (centrada em $E[I] = -1/(n-1)$, próximo de zero). O pseudo p-valor de 0,001 é o menor possível com 999 permutações e indica que nenhum arranjo aleatório produziu índice igual ou superior ao observado.




Figura 7. Distribuições de referência com 999 permutações. A linha verde marca o índice observado; o histograma reúne os índices dos mapas aleatorizados. A distância entre eles, resumida pelo z-value, mostra que a autocorrelação das três taxas não é obra do acaso, variando apenas a magnitude.

VARIÁVEL	MORAN'S I	Z-VALUE	PSEUDO P	LEITURA
tx_roubo	0,832	35,6	0,001	autocorrelação positiva forte
tx_furto	0,426	17,5	0,001	autocorrelação positiva moderada
tx_lesao	0,183	7,5	0,001	autocorrelação positiva fraca

5. Passo 4: índice local de Moran (LISA)

O LISA decompõe o índice global: cada município recebe um índice local que mede sua contribuição para a autocorrelação do conjunto. O mapa de agrupamento pinta apenas os municípios significativos ($p \leq 0,05$ por permutação condicional), classificados pelo quadrante

do diagrama de Moran: Alto-Alto (núcleo de concentração de taxas altas), Baixo-Baixo (concentração de taxas baixas) e os outliers espaciais Alto-Baixo e Baixo-Alto, municípios que destoam da própria vizinhança. O mapa de significância acompanha cada mapa de agrupamento e mostra a força da evidência em cada município (p de 0,05, 0,01 ou 0,001).




Figura 8. LISA da taxa de roubo: 50 municípios Alto-Alto formando um único complexo contíguo (RMSP e Baixada Santista), 148 municípios Baixo-Baixo no oeste e noroeste, e apenas 3 outliers espaciais. O estado aparece partido em duas realidades: um núcleo metropolitano de taxas altas e um vasto interior de taxas próximas de zero.




Figura 9. LISA da taxa de furto: 49 municípios Alto-Alto acompanhando o litoral de Ubatuba a Cananéia, com bolsões no norte do estado; 67 municípios Baixo-Baixo no oeste e centro-sul. Dos municípios do cluster Alto-Alto, 36% são litorâneos ou turísticos, a principal evidência espacial da nossa hipótese sobre população flutuante.




Figura 10. LISA da taxa de lesão corporal: 36 municípios Alto-Alto e 53 Baixo-Baixo em bolsões pequenos e fragmentados, sem formar complexos regionais. É o retrato de um índice global baixo: os clusters existem, mas são locais.

6. Validação cruzada com o pipeline em R

Todos os resultados do GeoDa foram conferidos contra o pipeline reprodutível do projeto (`Rscript run_espacial.R`, pacotes `sf` e `spdep`). A matriz de vizinhança apresentou estatísticas idênticas nos dois softwares. Os índices globais coincidiram até a segunda casa decimal; as pequenas diferenças (0,426 contra 0,422 no furto) vêm do tratamento de Ilhabela, que o GeoDa remove do cômputo e o R mantém na base.

VARIÁVEL	I (GEODA)	I (R)	ALTO-ALTO (GEODA / R)	BAIXO-BAIXO (GEODA / R)
tx_roubo	0,832	0,832	50 / 45	148 / 93
tx_furto	0,426	0,422	49 / 36	67 / 45
tx_lesao	0,183	0,181	36 / 22	53 / 28

Nota metodológica. Os clusters Alto-Alto, que sustentam nossas conclusões, aparecem nos mesmos lugares nos dois softwares. Já a extensão dos clusters, sobretudo dos Baixo-Baixo, depende do procedimento de inferência local: a aproximação analítica clássica quase não detecta cold spots em variáveis assimétricas cheias de zeros, enquanto a permutação condicional (usada pelo GeoDa e adotada no pipeline com `spdep::localmoran_perm`) os revela. Mesmo entre duas implementações de permutação os totais variam um pouco, por diferenças de sorteio e de critério de p-valor. Por isso o LISA deve ser lido pela geografia dos clusters, e não pela contagem exata de municípios.

7. Síntese

As três técnicas contam a mesma história em níveis diferentes. Os mapas temáticos mostram onde estão as taxas altas: RMSP e Baixada no roubo, litoral no furto, bolsões dispersos na lesão corporal. O índice global de Moran resume o quanto cada padrão é espacialmente estruturado, ordenando os crimes de forma consistente (roubo 0,832, furto 0,426, lesão 0,183, todos significativos a 0,001). O LISA localiza quais aglomerados sustentam esses índices e confirma que os crimes patrimoniais respondem a dinâmicas territoriais, enquanto a violência interpessoal se distribui de modo mais homogêneo.

Para o trabalho final, dois pontos ficam abertos. Primeiro, as taxas usam a população residente como denominador; em municípios turísticos de população flutuante alta, isso superestima o risco, e é justamente nesses municípios que o furto se aglomera. Segundo, a classificação de municípios litorâneos e turísticos usada na hipótese ainda é a lista default dos 16 municípios da costa e será revisada pelo grupo antes das análises confirmatórias.