

Análise de regressão linear clássica

A taxa de furto nos municípios de São Paulo explicada pela renda média e pela condição litorânea/turística

Equipe: João Vitor Oliveira, Julio Cesar Salvino e Lucas Amorim · **Orientação:** Prof.^a Flávia da Fonseca Feitosa
· Julho de 2026

1. Pergunta e dados

A hipótese que motivou nosso trabalho é se acontecem mais crimes nas cidades mais pobres. Para testá-la com regressão, tomamos como variável dependente a taxa de furto por 1.000 habitantes de cada um dos 645 municípios de São Paulo e como variável explicativa a renda média per capita do Censo 2022. Em seguida, avaliamos se a condição litorânea ou turística do município acrescenta poder de explicação, já que observamos no trabalho que as maiores taxas aparecem em cidades de população flutuante alta.

Escolhemos o furto entre os três crimes por ser o que apresenta a relação mais nítida com renda e território; as contagens brutas não servem para regressão porque acompanham o tamanho da população, e por isso trabalhamos com a taxa.

2. Análise exploratória

Antes de ajustar o modelo, usamos um gráfico de dispersão da taxa de furto contra a renda, com uma reta de tendência. Identificamos uma relação positiva: municípios de renda maior tendem a registrar mais furtos por habitante, o contrário do que a hipótese ingênua de que a pobreza gera crime faria esperar. Os municípios litorâneos e turísticos, em laranja, aparecem quase todos acima da reta, indicando que registram mais furtos do que a renda sozinha preveria.




Figura 1. Taxa de furto por 1.000 habitantes contra a renda média per capita. A faixa cinza é o intervalo de confiança da reta de tendência.

3. Regressão linear simples

Ajustamos o modelo de regressão linear simples da taxa de furto sobre a renda. A equação estimada é:

$$\text{taxa de furto} = 0,971 + 0,00247 \times \text{renda}$$

$$R^2 = 0,129 \cdot R^2 \text{ ajustado} = 0,128$$

A equação representa a reta que melhor descreve a relação média entre as duas variáveis. O coeficiente da renda, 0,00247, indica que cada R\$ 1 a mais de renda média está associado a 0,00247 furto a mais por 1.000 habitantes; em termos práticos, uma diferença de R\$ 1.000 na renda corresponde a cerca de 2,5 furtos a mais por 1.000 habitantes. O coeficiente é positivo e altamente significativo ($p < 0,001$), o que nos permite rejeitar a hipótese de que os furtos se concentram nos municípios mais pobres.

O R^2 de 0,129 mostra que a renda sozinha explica cerca de 13% da variação da taxa de furto entre os municípios. É uma cobertura baixa: sobra muita variação sem explicação, sinal de que faltam outros fatores no modelo.

4. Influência dos outliers na reta

Para entender de onde vem a variação não explicada, usamos a distância de Cook, que mede quanto cada município puxa o ajuste. Identificamos 29 municípios influentes (distância acima de $4/n$). Reajustando a reta sem eles, a inclinação da renda sobe de 0,00247 para 0,00288 e o R^2 passa de 0,13 para 0,19.




Figura 2. Municípios coloridos e dimensionados pela distância de Cook. A reta cheia usa todos os municípios; a tracejada exclui os influentes.

Os pontos mais influentes contam a história: Mongaguá e outros litorâneos ficam muito acima da reta (furto alto para a renda que têm), enquanto Santana de Parnaíba, de renda muito alta e furto baixo, puxa a reta para baixo pela ponta direita. Como esses municípios atípicos enfraquecem o ajuste em vez de serem apenas ruído, faz sentido tratar a condição litorânea de forma explícita, com uma variável própria, em vez de deixá-la escondida nos resíduos.

5. Regressão linear múltipla

Acrescentamos ao modelo a variável litorânea/turística, que vale 1 para os municípios do litoral e 0 para os demais (uma variável dummy). A equação estimada passa a ser:

$$\text{taxa de furto} = 1,036 + 0,00233 \times \text{renda} + 10,969 \times \text{litoral}$$

$$R^2 = 0,357 \cdot R^2 \text{ ajustado} = 0,355$$

Esta equação representa duas retas paralelas: uma para os municípios comuns e outra, deslocada para cima, para os litorâneos. O termo *litoral* assume apenas os valores 0 ou 1, então o seu coeficiente, 10,969, é exatamente a distância vertical entre as duas retas: um município litorâneo ou turístico registra, em média, quase 11 furtos a mais por 1.000 habitantes do que um município comum de mesma renda. O coeficiente da renda permanece praticamente igual ao do modelo simples (0,00233), o que mostra que os dois fatores agem de forma independente, confirmado pelo VIF igual a 1, sem multicolinearidade.

Ênfase no R^2 . A cobertura do modelo salta de 0,129 para 0,357 quando acrescentamos a condição litorânea, isto é, de 13% para 36% da variação explicada, quase o triplo. Só a renda deixava a maior parte do padrão sem explicação; a posição litorânea, associada à população flutuante turística, é a peça que faltava. Para dimensionar o efeito, o acréscimo de quase 11 furtos por 1.000 habitantes por ser litorâneo equivale ao efeito de uma diferença de renda de cerca de R\$ 4.700.

Modelo múltiplo: renda mais a condição litorânea/turística

O dummy desloca a reta: mesma inclinação da renda, patamar mais alto no litoral




Figura 3. As duas retas do modelo múltiplo. A inclinação (efeito da renda) é a mesma; o patamar (efeito litorâneo) é mais alto na reta laranja.

VARIÁVEL	MODELO SIMPLES	MODELO MÚLTIPLO	COM LOG DA RENDA
Renda média (R\$)	0,00247	0,00233	.
log(Renda)	.	.	6,603
Litorâneo/turístico	.	10,969	10,970
Constante	0,971	1,036	-44,651
R ²	0,129	0,357	0,359
R ² ajustado	0,128	0,355	0,357

Todos os coeficientes das três colunas são significativos a $p < 0,001$. A transformação logarítmica da renda, testada na terceira coluna seguindo a aula, melhora o ajuste de forma quase imperceptível (R^2 de 0,357 para 0,359), então mantemos o modelo em renda natural, cuja equação é mais fácil de interpretar.

6. Diagnóstico dos resíduos

Para verificar os pressupostos do modelo, examinamos os resíduos. O histograma mostra uma distribuição assimétrica à direita, com uma cauda de municípios de furto muito acima do previsto; o gráfico de resíduos contra valores ajustados mostra que a dispersão dos erros cresce quando o valor previsto aumenta.




Figura 4. Distribuição dos resíduos (esquerda) e resíduos contra valores ajustados (direita).

Confirmamos essas leituras com o Q-Q plot e com testes formais. No Q-Q plot, os resíduos acompanham a reta na parte central, mas a cauda direita se afasta para cima, indicando os municípios de furto atipicamente alto. O teste de Shapiro-Wilk rejeita a normalidade dos resíduos e o teste ncvTest rejeita a variância constante (ambos com $p < 0,001$).




Figura 5. Q-Q plot dos resíduos studentizados. A banda azul é o envelope de confiança sob normalidade.

Esses desvios eram esperados, porque as taxas de crime são muito assimétricas, e indicam que os p-valores devem ser lidos com cautela e que um modelo que trate a assimetria e a dependência espacial dos municípios seria o passo seguinte. Ainda assim, o resultado central é robusto: a renda tem efeito positivo e a condição litorânea acrescenta um salto grande e significativo na taxa de furto, e juntas as duas variáveis cobrem 36% da variação entre os municípios.

Fontes: SSP-SP (ocorrências de 2025) e IBGE, Censo 2022 (renda, população e malha municipal). Modelos ajustados por mínimos quadrados ordinários, com diagnóstico de resíduos por Q-Q plot, teste de Shapiro-Wilk e teste *ncvTest*.