

Furto, Renda e Território: Uma Análise Espacial da Criminalidade Patrimonial nos Municípios de São Paulo

João Vitor Oliveira, Julio Cesar Salvino, Lucas Amorim
Centro de Matemática, Computação e Cognição
Universidade Federal do ABC (UFABC)
Orientação: Prof.^a Flávia da Fonseca Feitosa
Análise de Dados para Planejamento Territorial

Resumo—Este trabalho investiga se municípios mais pobres do estado de São Paulo apresentam maiores taxas de criminalidade patrimonial, cruzando ocorrências registradas pela SSP-SP (2025) com a renda média per capita do Censo IBGE 2022 nos 645 municípios do estado. Partindo de uma análise exploratória e de correlação, mostramos que a relação entre renda e taxa de furto é, ao contrário da hipótese inicial, positiva. Investigamos essa relação com um ferramental progressivo de econometria espacial — correlação, autocorrelação espacial global e local (Moran’s I e LISA), regressão linear clássica, regressão espacial global (*spatial lag* e *spatial error*) e regressão geograficamente ponderada (GWR) — incorporando uma variável de condição litorânea/turística. O modelo final (GWR com renda e litoral) eleva o poder explicativo de $R^2 = 0,129$ (OLS simples) para $R^2 = 0,532$, com o menor AIC entre os modelos testados. Os resultados indicam que a criminalidade patrimonial responde muito mais à condição litorânea/turística e à não-estacionariedade espacial da relação renda-furto do que à renda em si, isoladamente.

Index Terms—análise espacial, autocorrelação espacial, regressão geograficamente ponderada, criminalidade, planejamento territorial

I. INTRODUÇÃO

A pergunta que orienta este trabalho é direta: acontecem mais crimes nas cidades mais pobres? Essa hipótese (H1), amplamente difundida no senso comum sobre criminalidade, foi o ponto de partida da pesquisa, desenvolvida na disciplina de Análise de Dados para Planejamento Territorial da UFABC. Para testá-la, tomamos como variável dependente a taxa de furto (art. 155) por 1.000 habitantes dos 645 municípios de São Paulo e como variável explicativa a renda média per capita.

Optamos por trabalhar com taxas, e não contagens brutas de ocorrências, porque a contagem acompanha o tamanho da população: qualquer mapa de contagem destaca a capital e as cidades grandes independentemente do fenômeno investigado, enquanto a taxa permite comparar municípios de portes muito diferentes.

Ao longo da análise exploratória, emergiu uma segunda hipótese (H2): municípios litorâneos e turísticos concentram taxas de criminalidade patrimonial mais altas, não porque sejam mais pobres, mas porque sua população flutuante de verão infla o numerador da taxa (ocorrências) sobre um denominador que mede apenas a população residente. Essa

hipótese exploratória guiou boa parte do desenvolvimento metodológico deste trabalho, da regressão múltipla à regressão geograficamente ponderada (GWR).

O restante deste artigo está organizado da seguinte forma: a Seção II descreve os dados e variáveis utilizados; a Seção III apresenta a metodologia; a Seção IV percorre o desenvolvimento da análise, do exploratório à GWR; e a Seção V conclui.

II. DADOS E VARIÁVEIS

A unidade de análise são os 645 municípios do estado de São Paulo, com dados de criminalidade da SSP-SP [6] e de renda e população do Censo IBGE 2022 [5]. A Tabela I resume as variáveis utilizadas.

Tabela I
VARIÁVEIS UTILIZADAS NA ANÁLISE

Variável	Fonte	Descrição
Taxa de roubo (art. 157)	SSP-SP, 2025	Ocorrências por 1.000 hab.
Taxa de furto (art. 155)	SSP-SP, 2025	Ocorrências por 1.000 hab.
Taxa de lesão corporal (art. 129)	SSP-SP, 2025	Ocorrências por 1.000 hab.
Renda média	IBGE, Censo 2022	Renda per capita em R\$
População	IBGE, Tabela 4709	Denominador das taxas
Litorâneo/turístico	Classificação do grupo	Dummy (1/0), 16 municípios da costa paulista

A junção entre as bases criminal e de renda usa o código IBGE de 7 dígitos como chave, nunca o nome do município: a base da SSP abrevia nomes (ex. “S BARBARA D OESTE”), o que exige uma resolução em cascata (correspondência exata → expansão de abreviações → remoção de preposições → distância de edição ≤ 1) para evitar perdas de observações.

Entre os três crimes disponíveis, o furto foi escolhido como variável dependente principal por apresentar a relação mais nítida com renda e território ao longo da análise exploratória.

III. METODOLOGIA

A vizinhança espacial utilizada em todas as etapas é a contiguidade *queen* de ordem 1 (dois municípios são vizinhos se compartilham qualquer trecho de fronteira), com pesos normalizados por linha (*row-standardization*). Essa matriz tem 645 observações, mínimo de 0 e máximo de 22 vizinhos, média de 5,50. Ilhabela, por ser arquipélago, fica sem vizinhos (*zero.policy* = TRUE).

A análise segue quatro etapas progressivas:

- 1) **Correlação e autocorrelação espacial:** correlações de Pearson e Spearman entre as taxas de crime e a renda; índice global de Moran [1] e sua decomposição local (LISA) [2], com significância avaliada por permutação condicional (999 permutações), mais robusta que a versão analítica para variáveis assimétricas com muitos zeros.
- 2) **Regressão linear clássica (OLS):** modelo simples ($\text{taxa} \sim \text{renda}$) e múltiplo ($\text{taxa} \sim \text{renda} + \text{litoral}$), com diagnóstico de resíduos (Shapiro-Wilk, *ncvTest*, distância de Cook).
- 3) **Regressão espacial global:** testes de Multiplicadores de Lagrange (LM) para escolher entre *spatial lag* (ρ) e *spatial error* (λ), ambos por máxima verossimilhança.
- 4) **Regressão Geograficamente Ponderada (GWR)** [4]: ajusta uma regressão local para cada município, com pesos decaindo por um núcleo gaussiano $w_{ij} = \exp(-\frac{1}{2}(d_{ij}/h)^2)$ em função da distância geográfica d_{ij} , onde a banda h é adaptativa (definida pelo k -ésimo vizinho mais próximo, $k \approx 10$, escolhido por validação cruzada).

IV. DESENVOLVIMENTO E RESULTADOS

A. Análise exploratória

A Fig. 1 mostra a distribuição espacial da taxa de furto por 1.000 habitantes. O padrão visual já sugere concentração na macrometrópole e no litoral, contrariando a intuição de que a criminalidade patrimonial se concentraria nas regiões mais pobres do interior.

Mapas complementares (por desvio padrão e *box map*, não reproduzidos aqui por espaço) confirmam o padrão: o *box map* identifica 17 outliers superiores na taxa de furto, concentrados no litoral e na capital, contra 60 outliers superiores na taxa de roubo, quase todos contíguos na RMSP e na Baixada Santista.

A dispersão de cada taxa contra a renda média (Fig. 2) ajuda a justificar a escolha do furto como variável dependente principal: no roubo, o outlier mais extremo é de um município não litorâneo, e os litorâneos aparecem elevados sem dominar o topo da distribuição; na lesão corporal, o outlier extremo é de renda baixíssima e não litorâneo, com os litorâneos perdidos no meio da nuvem de pontos; já no furto, os outliers extremos são quase todos litorâneos — Mongaguá e outros municípios da costa aparecem bem acima da nuvem geral. É o único dos três crimes em que o padrão litorâneo aparece nitidamente nos extremos da distribuição.

Furto (art. 155) — taxa por 1.000 habitantes
Municípios de São Paulo, 2025 — classes por quintis




Figura 1. Taxa de furto por 1.000 habitantes, municípios de SP (classes por quintis).




Figura 2. Dispersão das taxas de roubo, furto e lesão corporal (por 1.000 hab.) contra a renda média, com destaque para os municípios litorâneos/turísticos.

B. Correlação

A Tabela II mostra as correlações entre as taxas de crime e a renda média. Roubo e furto correlacionam *positivamente* com a renda — o oposto do que H1 previa — enquanto a lesão corporal correlaciona negativamente, embora de forma fraca.

Tabela II
CORRELAÇÃO ENTRE TAXAS DE CRIME E RENDA

Par	Pearson	Spearman
Roubo $\times$ Renda	0,302	0,389
Furto $\times$ Renda	0,359	0,380
Lesão corporal $\times$ Renda	-0,190	-0,166

C. Autocorrelação espacial: Moran global e LISA

O índice global de Moran [1] mede o grau em que valores semelhantes se aglomeram no espaço, operacionalizando a chamada primeira lei da geografia — a ideia de que lugares próximos tendem a se parecer mais entre si do que lugares




Figura 3. Matriz de correlação entre as taxas de crime e a renda média.

distantes [3]. A Tabela III mostra que a taxa de roubo tem autocorrelação espacial forte ($I = 0,832$), a de furto moderada ($I = 0,422$) e a de lesão corporal fraca ($I = 0,181$), todas significativas a $p = 0,001$ por permutação (999 simulações).

Tabela III
ÍNDICE GLOBAL DE MORAN POR CRIME

Variável	Moran's I	p (perm.)	Leitura
Taxa de roubo	0,832	0,001	forte
Taxa de furto	0,422	0,001	moderada
Taxa de lesão corporal	0,181	0,001	fraca

A decomposição local (LISA [2], Fig. 4) mostra, para o furto, 36 municípios no cluster Alto-Alto acompanhando o litoral de Ubatuba a Cananéia, e 45 municípios Baixo-Baixo no oeste e centro-sul. Dos municípios do cluster Alto-Alto, 36% são litorâneos ou turísticos — primeira evidência quantitativa a favor de H2.¹

D. Regressão linear clássica

O modelo simples (Fig. 5) estima:

$$\text{taxa de furto} = 0,971 + 0,00247 \cdot \text{renda}, \quad R^2 = 0,129 \quad (1)$$

O coeficiente positivo e significativo ($p < 0,001$) confirma que a hipótese H1 não se sustenta: mais renda está associada a *mais* furto, não menos. O R^2 de 0,129 indica, porém, baixo poder explicativo isolado.

A distância de Cook identifica 29 municípios influentes (Fig. 6); ao excluí-los, a inclinação da renda sobe de 0,00247 para 0,00288 e o R^2 de 0,13 para 0,19 — ou seja, o efeito

¹Os mesmos dados processados no GeoDa (permutação condicional independente) indicam 49 municípios Alto-Alto e 67 Baixo-Baixo para o furto — a mesma geografia de clusters, com contagens um pouco maiores. Reportamos aqui os números do R (`spdep::localmoran_perm`), a mesma implementação usada no Moran's I global da Tabela III, para manter os dois números consistentes entre si; ver `docs/guia_geoda.md` para a comparação completa R $\times$ GeoDa.




Figura 4. Clusters LISA da taxa de furto ($p \leq 0,05$, vizinhança queen).




Figura 5. Taxa de furto contra renda média, com reta de tendência.

positivo não é artefato de poucos pontos extremos, e se fortalece sem eles. Os municípios mais influentes são, no entanto, informativos: Mongaguá e outros litorâneos ficam muito acima da reta, e Santana de Parnaíba (renda alta, furto baixo) puxa a reta para baixo pela direita.

Isso motiva incluir explicitamente a condição litorânea/turística como variável dummy:

$$\text{taxa de furto} = 1,036 + 0,00233 \cdot \text{renda} + 10,969 \cdot \text{litoral} \quad (2)$$

com $R^2 = 0,357$ ($R^2_{\text{ajustado}} = 0,355$). O coeficiente da renda pouco muda em relação ao modelo simples (VIF=1, sem multicolinearidade), e o termo litoral, de 10,969, é a distância vertical entre as retas dos dois grupos (Fig. 7): um município litorâneo registra, em média, quase 11 furtos a mais por 1.000 habitantes do que um município comum de mesma renda — efeito equivalente a uma diferença de renda de cerca de R\$4.700.

Diagnósticos formais (Shapiro-Wilk, `ncvTest`, ambos $p < 0,001$) rejeitam normalidade e homocedasticidade dos resíduos — esperado dada a assimetria das taxas de crime — e motivam




Figura 6. Influência dos municípios na reta de tendência (distância de Cook).




Figura 7. Modelo múltiplo: retas paralelas por condição litorânea.

avancar para modelos que tratem a estrutura espacial dos dados.

E. Regressão espacial global

O Moran's I dos resíduos do modelo clássico é 0,38 ($p < 0,001$): a autocorrelação espacial não explicada é elevada, violando a premissa de independência do OLS. Os testes de Multiplicadores de Lagrange (Tabela IV) indicam, pela versão robusta, o modelo *spatial error* como mais adequado (Robust LM error significativo, Robust LM lag não significativo).

Tabela IV
TESTES DE MULTIPLICADORES DE LAGRANGE

Teste	Estatística	p-valor
LM (lag)	217,4	< 0,001
LM (error)	238,9	< 0,001
Robust LM (lag)	1,23	0,267
Robust LM (error)	22,8	< 0,001

O modelo *spatial error* ($\lambda = 0,588$, $R^2 = 0,392$, AIC= 3220,6) supõe que a dependência espacial está no erro, refletindo uma variável omitida e espacialmente agrupada — coerente com a hipótese de que é a condição litorânea, e não um efeito de contágio entre vizinhos, que gera o padrão espacial. Após o ajuste, o Moran's I dos resíduos cai de

0,38 para $-0,03$, praticamente eliminando a autocorrelação residual.

F. Regressão Geograficamente Ponderada (GWR)

O GWR relaxa a suposição de que a relação renda-furto é constante no espaço. Com banda adaptativa ($k \approx 10$ vizinhos), o R^2 quase-global sobe para 0,458 (Fig. 8), superando os modelos globais. O coeficiente local da renda varia de $-0,00216$ a $+0,00562$ pelo estado, positivo na maior parte e invertido num bolsão do noroeste; a estatística t é significativa ($|t| > 1,96$) em 72% dos municípios.




Figura 8. R^2 local do GWR (taxa de furto $\sim$ renda).

O R^2 local varia de 0,05 a 0,64: a renda explica bem a taxa de furto no centro-oeste do estado e mal no litoral e na Região Metropolitana — justamente onde a população flutuante turística deveria dominar o fenômeno, segundo H2.

G. GWR com a variável litorânea e cenário contrafactual

Ajustando GWR com renda e litoral, o R^2 quase-global sobe para 0,532 e o AIC cai para 3027,4, o melhor entre todos os modelos testados (Tabela V). Os coeficientes locais (Fig. 9) mostram que o efeito litorâneo varia de 0 a 22 furtos/1.000 hab. conforme o município.




Figura 9. Coeficientes locais da renda (esq.) e da condição litorânea (dir.), modelo GWR com as duas variáveis.

Complementarmente, a Fig. 10 mapeia a estatística t local de cada variável — uma leitura contínua de magnitude e significância, mais informativa que um simples corte binário em $|t| > 1,96$: o efeito da renda é significativo ($|t| > 1,96$) na quase totalidade do estado, com exceção de um bolsão no extremo noroeste; o efeito litorâneo é significativo em praticamente todos os municípios, mas sua magnitude cresce à medida que se caminha do noroeste em direção à metade sul-sudeste do estado, com o pico concentrado na faixa que vai da Região Metropolitana à Baixada Santista — coerente com a leitura de que o efeito litorâneo se espalha por contágio espacial do GWR para além dos 16 municípios classificados como litorâneos/turísticos, e não fica restrito a uma faixa estreita no litoral.




Figura 10. Estatística t local da renda (esq.) e da condição litorânea (dir.), modelo GWR com as duas variáveis.

Para isolar o efeito litorâneo, construímos um cenário contrafactual: mantendo os coeficientes locais do GWR, zeramos a variável litoral e recalculamos a predição (Fig. 11). A diferença entre a predição real e a contrafactual — de até 12 furtos/1.000 hab. — concentra-se inteiramente na faixa costeira.




Figura 11. Impacto contrafactual da condição litorânea sobre a taxa de furto prevista.

Como leitura complementar, ajustamos regressões separadas por regime espacial (Fig. 12): no interior, a taxa de furto cresce com a renda ($R^2 = 0,19$); no litoral, a reta é praticamente

plana, num patamar bem mais alto ($R^2 = 0,008$) — ou seja, dentro do próprio grupo litorâneo, a renda não explica a variação do furto.




Figura 12. Regressão por regime: litoral (laranja) contra interior (azul), e modelo global (tracejado).

Por fim, o tratamento dos resíduos confirma o mecanismo (Fig. 13): sem a variável litoral, os municípios litorâneos têm resíduo médio de +10,68 furtos/1.000 hab. contra $-0,27$ dos demais; ao incluir a variável, os dois grupos centram em zero. A correlação entre o resíduo (sem litoral) e a dummy litorânea é 0,51 e cai para 0,00 com a variável incluída.




Figura 13. Resíduos por grupo, com e sem a variável litorânea no modelo.

H. Comparação final dos modelos

A Tabela V compara os três tipos de modelo (OLS, *spatial error* e GWR) com e sem a variável litorânea, lado a lado, para isolar o efeito de cada camada de complexidade. A condição litorânea melhora o ajuste em todos os três casos, mas o ganho é desigual: é maior no modelo mais simples ($\Delta R^2 = +0,228$ no OLS) e menor nos modelos espaciais ($\Delta R^2 = +0,052$ no *spatial error*; $+0,074$ no GWR) — sinal de que os modelos espaciais já capturavam parte do padrão litorâneo implicitamente, antes mesmo de a variável entrar explicitamente. O melhor modelo entre todos os testados é o GWR com renda e litoral, com $R^2 = 0,532$ e o menor AIC (3027,4).

Tabela V
COMPARAÇÃO DE TODOS OS MODELOS AJUSTADOS (R^2)

Modelo	Sem litoral	Com litoral	Δ
OLS	0,129	0,357	+0,228
Spatial Error	0,392	0,444	+0,052
GWR	0,458	0,532	+0,074

V. CONCLUSÃO

A hipótese original deste trabalho — de que municípios mais pobres registram mais crimes patrimoniais — não se sustenta nos dados de São Paulo: a relação entre renda e taxa de furto é positiva, não negativa, tanto na correlação simples quanto em todos os modelos de regressão testados. A explicação mais consistente com a evidência acumulada é a hipótese exploratória H2: municípios litorâneos e turísticos concentram taxas elevadas de criminalidade patrimonial porque sua população flutuante de verão infla o numerador da taxa sobre um denominador que mede apenas residentes.

A progressão metodológica — de correlação a Moran's I e LISA, de OLS a *spatial error* e finalmente a GWR — revela três camadas distintas do fenômeno: (i) a renda sozinha é insuficiente e deixa estrutura espacial não explicada nos resíduos; (ii) essa estrutura é majoritariamente absorvida por uma única variável omitida e espacialmente agrupada, a condição litorânea; (iii) mesmo controlando por essa variável, a própria relação renda-furto não é estacionária no espaço, sendo razoavelmente forte no interior e quase nula no litoral, onde a dinâmica turística domina. O modelo final (GWR com renda e litoral, $R^2 = 0,532$) combina essas duas camadas e obtém o melhor ajuste entre todos os testados.

Como direção futura, a inclusão de uma medida direta de fluxo turístico (hospedagem, pedágios, dados de telefonia) permitiria testar diretamente o mecanismo proposto, hoje capturado apenas indiretamente por uma variável dummy.

AGRADECIMENTOS

Os autores agradecem à Prof.^a Flávia da Fonseca Feitosa pela orientação ao longo da disciplina de Análise de Dados para Planejamento Territorial.

REFERÊNCIAS

- [1] P. A. P. Moran, "Notes on continuous stochastic phenomena," *Biometrika*, vol. 37, no. 1/2, pp. 17–23, 1950.
- [2] L. Anselin, "Local indicators of spatial association—LISA," *Geographical Analysis*, vol. 27, no. 2, pp. 93–115, 1995.
- [3] W. R. Tobler, "A computer movie simulating urban growth in the Detroit region," *Economic Geography*, vol. 46, sup. 1, pp. 234–240, 1970.
- [4] A. S. Fotheringham, C. Brunson, and M. Charlton, *Geographically Weighted Regression: The Analysis of Spatially Varying Relationships*. Chichester: John Wiley & Sons, 2002.
- [5] Instituto Brasileiro de Geografia e Estatística (IBGE), *Censo Demográfico 2022*. [Online]. Disponível em: <https://censo2022.ibge.gov.br>
- [6] Secretaria de Segurança Pública do Estado de São Paulo (SSP-SP), *Dados Estatísticos do Estado de São Paulo, 2025*. [Online]. Disponível em: <https://www.ssp.sp.gov.br>